

最优化方法

Methods of Optimization

目录

第一章 基础知识

1.1 数学规划

规划论，又称数学规划，是运筹学的分支，研究在约束条件下通过分配资源寻求目标函数极值的数学方法，应用于经济管理、工程设计和过程控制等领域。其核心是建立约束条件与目标函数的数学模型，这种数学模型的一般形式为

$$\begin{aligned} \text{Opt. } & f(x_i, y_j, \xi_k) \\ \text{s.t. } & g_h(x_i, y_j, \xi_k) \leq (=, \geq) 0 \\ & h = 1, 2, \dots, m \end{aligned}$$

其中， x_i 是控制变量， y_j 是已知参数， ξ_k 是随机因素， f 是目标函数， g_h 是约束函数。

按照目标函数和自变量取值范围的不同，数学规划可分为：

- 线性规划： f, g 都是线性函数；
- 非线性规划： f, g 中有非线性函数；
- 多目标规划： f 是向量函数；
- 整数规划：决策变量 x_i 为整数；
- 动态规划：含多阶段决策过程；
- 随机规划：含有随机因子。

若记

$$S = \{\mathbf{x} \mid g_h(x_i, y_j, \xi_k) \leq (=, \geq) 0\} \subseteq \mathbb{R}^n$$

为约束集合，则这种数学模型可进一步简记为

$$(f \ S) \begin{cases} \min & f(\mathbf{x}) \\ \text{s.t.} & \mathbf{x} \in S \end{cases}$$

其中 $\mathbf{x} \in S$ 称模型 $(f \ S)$ 的可行解。

定义 1.1 （全局最优解、最优值）

若对于 $\mathbf{x}^* \in S$ ，满足 $f(\mathbf{x}^*) \leq f(\mathbf{x})$ ， $\forall \mathbf{x} \in S$ ，则称 \mathbf{x}^* 为 $(f \ S)$ 的全局最优解（最优解），记作 g.opt. ，简记为 opt. 。称此时的 $f(\mathbf{x}^*)$ 为 $(f \ S)$ 的最优值（最优目标函数值）。

定义 1.2 (局部最优解)

若对于 $\mathbf{x}^* \in S$, $\exists \mathbf{x}^*$ 的某邻域 $U(\mathbf{x}^*)$, 使得 $f(\mathbf{x}^*) \leq f(\mathbf{x})$, $\forall \mathbf{x} \in S$, 则称 \mathbf{x}^* 为 (f, S) 的局部最优解, 记作 l.opt.,

在上述定义中, 若当 $\mathbf{x} \neq \mathbf{x}^*$ 时有严格不等式成立, 则分别称 \mathbf{x}^* 为 (f, S) 的严格全局最优解和严格局部最优解.

1.2 基本概念和符号

接下来将约定一些术语的符号表示:

- \mathbb{R}^n —— n 维欧式空间;
- $\mathbf{x} = (x_1, x_2, \dots, x_n)^\top \in \mathbb{R}^n$ ——表示 \mathbb{R}^n 中的一个点或一个向量, 其中分量 $x_i \in \mathbb{R}$;
- $\mathbf{d} = (d_1, d_2, \dots, d_n)^\top \in \mathbb{R}^n$, 其中 $\mathbf{d} \neq \mathbf{0}$ ——表示从 0 指向 \mathbf{d} 的方向. 此外, 设 $\mathbf{d}^{(1)}, \mathbf{d}^{(2)} \in \mathbb{R}^n$, 若 $\exists \lambda > 0$, 使得 $\mathbf{d}^{(1)} = \lambda \mathbf{d}^{(2)}$, 则称 $\mathbf{d}^{(1)}, \mathbf{d}^{(2)}$ 是同方向的.
- $\mathbf{x} + \lambda \mathbf{d}$ ——表示从 \mathbf{x} 点出发, 沿 \mathbf{d} 方向移动 $\lambda \mathbf{d}$ 长度得到的点.

下面是对欧式空间中向量的运算的定义.

定义 1.3 (向量的运算)

设 $\mathbf{x} = (x_1, x_2, \dots, x_n)^\top \in \mathbb{R}^n$, $\mathbf{y} = (y_1, y_2, \dots, y_n)^\top \in \mathbb{R}^n$, 则

$$(1) \text{ 向量的内积运算: } \mathbf{x}^\top \mathbf{y} = \mathbf{y}^\top \mathbf{x} = \sum_{i=1}^n x_i y_i;$$

$$(2) \text{ 向量长度: } \|\mathbf{x}\| = \sqrt{\mathbf{x}^\top \mathbf{x}} = \sqrt{\sum_{i=1}^n x_i^2};$$

$$(3) \text{ 两点间距离: } \|\mathbf{x} - \mathbf{y}\|.$$

定理 1.1 (三角不等式)

$\forall \mathbf{x}, \mathbf{y} \in \mathbb{R}^n$, 有

$$\|\mathbf{x} + \mathbf{y}\| \leq \|\mathbf{x}\| + \|\mathbf{y}\| \quad (1.1)$$

定义 1.4 (点列的收敛)

设 $\{\mathbf{x}^{(n)}\}$ 是定义在 \mathbb{R}^n 上的点列, 若 $\exists \mathbf{x} \in \mathbb{R}^n$, 使得 $\lim_{n \rightarrow \infty} \|\mathbf{x}^{(n)} - \mathbf{x}\| = 0$, 则称点列 $\{\mathbf{x}^{(n)}\}$ 收敛到 \mathbf{x} , 记作

$$\lim_{n \rightarrow \infty} \mathbf{x}^{(n)} = \mathbf{x}$$

定义 1.5 (向量的大小关系)

设 $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$, 若 $\forall i \in \{1, 2, \dots, n\}$, 都有 $x_i \leq y_i$, 则称 $\mathbf{x} \leq \mathbf{y}$. 类似可规定 $\mathbf{x} \geq \mathbf{y}$, $\mathbf{x} < \mathbf{y}$, $\mathbf{x} > \mathbf{y}$.

显然, 在如上定义中, (\mathbb{R}^n, \leq) 并不是全序集(证明略). 特别地, $\mathbf{x} \leq \mathbf{0} \Leftrightarrow \forall i \in \{1, 2, \dots, n\}, x_i \leq 0$.

定理 1.2

设 $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$, 若 $\forall \mathbf{y} \geq \mathbf{0}$, 都有 $\mathbf{x}^\top \mathbf{y} \leq \alpha$, 则有 $\mathbf{x} \leq \mathbf{0}$ 且 $\alpha \geq 0$.

该命题还有以下等价表述:

- 若 $\forall \mathbf{y} \leq \mathbf{0}$, 都有 $\mathbf{x}^\top \mathbf{y} \leq \alpha$, 则有 $\mathbf{x} \geq \mathbf{0}$ 且 $\alpha \geq 0$;

- 若 $\forall \mathbf{y} \geq 0$, 都有 $\mathbf{x}^\top \mathbf{y} \geq \alpha$, 则有 $\mathbf{x} \geq 0$ 且 $\alpha \leq 0$;
- 若 $\forall \mathbf{y} \leq 0$, 都有 $\mathbf{x}^\top \mathbf{y} \geq \alpha$, 则有 $\mathbf{x} \leq 0$ 且 $\alpha \leq 0$.

1.3 子空间、正交子空间

定义 1.6 (子空间)

设 $\mathbf{d}^{(i)} \in \mathbb{R}^n, i = 1, 2, \dots, m$ 是线性无关的向量组, 称集合 $\{\mathbf{x} \mid \mathbf{x} = \sum_{j=1}^m \alpha_j \mathbf{d}^{(j)}, \alpha_j \in \mathbb{R}\}$ 是由向量 $\mathbf{d}^{(1)}, \mathbf{d}^{(2)}, \dots, \mathbf{d}^{(m)}$ 生成的子空间, 记作 $L(\mathbf{d}^{(1)}, \mathbf{d}^{(2)}, \dots, \mathbf{d}^{(m)})$, 简记作 L .

可以看到, $\forall L \subseteq \mathbb{R}^n$, 都有 $0 \in L$. 若令 $\mathbf{A} = (\mathbf{d}^{(1)}, \mathbf{d}^{(2)}, \dots, \mathbf{d}^{(m)}) \in \mathbb{R}^{n \times m}, \boldsymbol{\alpha} = (\alpha_1, \alpha_2, \dots, \alpha_m)^\top \in \mathbb{R}^m$, 则

$$\mathbf{x} \in L \Leftrightarrow \exists \boldsymbol{\alpha} \in \mathbb{R}^m, \mathbf{x} = \mathbf{A}\boldsymbol{\alpha}$$

并且 $\text{Rank}(\mathbf{A}) = m$, 也就是说 \mathbf{A} 是列满秩的. 我们将会在接下来的证明中用到这个性质.

定义 1.7 (正交子空间)

称集合 $\{\mathbf{x} \in \mathbb{R}^n \mid \mathbf{x}^\top \mathbf{y} = 0, \forall \mathbf{y} \in L\}$ 为子空间 L 的正交子空间, 记作 L^\perp .

不难看出 $\forall L \subseteq \mathbb{R}^n$, 都有 $0 \in L^\perp$. 且有

$$\begin{aligned} \mathbf{x} \in L^\perp &\Leftrightarrow \forall \mathbf{y} \in L, \mathbf{x}^\top \mathbf{y} = 0 \\ &\Leftrightarrow \forall \boldsymbol{\alpha} \in \mathbb{R}^m, \mathbf{x}^\top \mathbf{A}\boldsymbol{\alpha} = 0 \end{aligned}$$

定理 1.3 (子空间投影定理)

设 L 为 \mathbb{R}^n 的子空间, 则 $\forall \mathbf{z} \in \mathbb{R}^n$, 则必有以下两个命题成立:

- (1) $\exists! \mathbf{x} \in L, \mathbf{y} \in L^\perp$, 使得 $\mathbf{z} = \mathbf{x} + \mathbf{y}$;
- (2) 在 (1) 中的 \mathbf{x} 为问题

$$\begin{aligned} \min_{\mathbf{u}} \quad & \|\mathbf{z} - \mathbf{u}\| \\ \text{s.t.} \quad & \mathbf{u} \in L \end{aligned}$$

的唯一解, 且该问题的最优值为 (1) 中的 $\|\mathbf{y}\|$.

定理 1.4

设 $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$, 若 $\forall \mathbf{y} \in L$, 都有 $\mathbf{x}^\top \mathbf{y} \leq \alpha$, 则有 $\mathbf{x} \in L^\perp$ 且 $\alpha \geq 0$.

该命题还有以下等价表述:

- 若 $\forall \mathbf{y} \in L$, 都有 $\mathbf{x}^\top \mathbf{y} \geq \alpha$, 则有 $\mathbf{x} \in L^\perp$ 且 $\alpha \leq 0$.

1.4 多元函数及其导数

多元函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 可看作一个 n 维向量 \mathbf{x} 的函数 $f(\mathbf{x})$. 受篇幅所限, 我们并不给出矩阵导数的定义, 具体请参见《矩阵分析》课程相关内容. 在此我们只给出梯度 (一阶偏导数向量) 和 Hesse 阵 (二阶偏导数矩阵).

定义 1.8 (梯度、Hesse 阵)

设函数 $f: S \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$ 在其定义域上分别一阶可微和二阶可微, 则

$$(1) \text{ 梯度 } \nabla f(\mathbf{x}) = \left(\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \dots, \frac{\partial f}{\partial x_n} \right)^\top;$$

$$(2) \text{ Hesse 阵 } \nabla^2 f(\mathbf{x}) = \begin{pmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_2 \partial x_1} & \cdots & \frac{\partial^2 f}{\partial x_n \partial x_1} \\ \frac{\partial^2 f}{\partial x_1 \partial x_2} & \frac{\partial^2 f}{\partial x_2^2} & \cdots & \frac{\partial^2 f}{\partial x_n \partial x_2} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_1 \partial x_n} & \frac{\partial^2 f}{\partial x_2 \partial x_n} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{pmatrix}$$

定理 1.5 (一些常见函数的梯度)

- 线性函数: $f(\mathbf{x}) = \mathbf{c}^\top \mathbf{x} + d$, $\nabla f(\mathbf{x}) = \mathbf{c}$, $\nabla^2 f(\mathbf{x}) = 0$;
- 二次函数: $f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{Q} \mathbf{x} + \mathbf{c}^\top \mathbf{x} + d$, $\nabla f(\mathbf{x}) = \mathbf{Q} \mathbf{x} + \mathbf{c}$, $\nabla^2 f(\mathbf{x}) = \mathbf{Q}$, 其中 \mathbf{Q} 为对称阵.
- 向量值线性函数: $\mathbf{f}(\mathbf{x}) = \mathbf{A} \mathbf{x} + \mathbf{d} \in \mathbb{R}^m$, $\frac{d\mathbf{f}}{d\mathbf{x}} = \mathbf{A}^\top$.

例 1.1 求下列函数的梯度和 Hesse 矩阵.

- (1) $f_1(\mathbf{x}) = x_2^1 - x_1 + x_2^2 + x_1 x_2 + 9$;
- (2) $f_2(\mathbf{x}) = 2x_2^1 + x_2^2 + 5x_3^2 + 3x_1 x_2 - 6x_1 x_3 + 4x_1 x_2 x_3 + 17$;
- (3) $f_3(\mathbf{x}) = 10 - (x_2 - x_1^2)^2$.

接下来依旧不加证明地介绍多元函数的 Taylor 展开式及中值定理. 此处不加证明是因为此内容可以被读者在任何一本《数学分析》教材中找到.

定理 1.6 (Taylor 展开式)

设 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 在 \mathbf{x}^* 的某邻域内分别一阶、二阶可微, 则分别有:

- 一阶 Taylor 展开式: $f(\mathbf{x}) = f(\mathbf{x}^*) + \nabla f^\top(\mathbf{x}^*)(\mathbf{x} - \mathbf{x}^*) + o(\|\mathbf{x} - \mathbf{x}^*\|)$;
- 二阶 Taylor 展开式: $f(\mathbf{x}) = f(\mathbf{x}^*) + \nabla f^\top(\mathbf{x}^*)(\mathbf{x} - \mathbf{x}^*) + \frac{1}{2}(\mathbf{x} - \mathbf{x}^*)^\top \nabla^2 f(\mathbf{x}^*)(\mathbf{x} - \mathbf{x}^*) + o(\|\mathbf{x} - \mathbf{x}^*\|^2)$.

定理 1.7 (中值定理)

设 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 在 \mathbf{x}^* 的某邻域 $U(\mathbf{x}^*)$ 内二阶可导, 则 $\forall \mathbf{x} \in U(\mathbf{x}^*)$, 都有:

- Lagrange 中值定理: $\exists \lambda \in (0, 1)$, 记 $\mathbf{x}_\lambda = \mathbf{x}^* + \lambda(\mathbf{x} - \mathbf{x}^*)$, 则有

$$f(\mathbf{x}) = f(\mathbf{x}^*) + \nabla f^\top(\mathbf{x}_\lambda)(\mathbf{x} - \mathbf{x}^*)$$

- Taylor 中值定理: $\exists \mu \in (0, 1)$, 记 $\mathbf{x}_\mu = \mathbf{x}^* + \mu(\mathbf{x} - \mathbf{x}^*)$, 则有

$$f(\mathbf{x}) = f(\mathbf{x}^*) + \nabla f^\top(\mathbf{x}^*)(\mathbf{x} - \mathbf{x}^*) + \frac{1}{2}(\mathbf{x} - \mathbf{x}^*)^\top \nabla^2 f(\mathbf{x}_\mu)(\mathbf{x} - \mathbf{x}^*)$$

定义 1.9 (方向导数)

设 $S \subseteq \mathbb{R}^n$ 为非空凸集, 函数 $f: S \rightarrow \mathbb{R}$, $\mathbf{x}^* \in S$, 方向 $\mathbf{d} \in \mathbb{R}^n$, 若 $\exists \lambda > 0$, 使得 $\mathbf{x}^* + \lambda \mathbf{d} \in S$ (通常令 λ 充分小, 此时称 \mathbf{d} 为可行方向), 且此时极限

$$\lim_{\lambda \rightarrow 0^+} \frac{f(\mathbf{x}^* + \lambda \mathbf{d}) - f(\mathbf{x}^*)}{\lambda}$$

存在, 则称 $f(\mathbf{x})$ 在点 \mathbf{x}^* 沿方向 \mathbf{d} 的方向导数存在, 记作 $f'(\mathbf{x}^*; \mathbf{d})$.

定理 1.8 (方向导数和梯度的关系)

若 $f(\mathbf{x})$ 在 \mathbf{x}^* 处可微, 则

$$f'(\mathbf{x}^*; \mathbf{d}) = \nabla f^\top(\mathbf{x}^*) \mathbf{d}$$

1.5 凸集、凸函数和凸规划

1.5.1 凸集

1. 凸集、凸组合

定义 1.10 (凸集)

设 $S \subseteq \mathbb{R}^n$, 若 $\forall \mathbf{x}^{(1)}, \mathbf{x}^{(2)} \in S, \lambda \in [0, 1]$, 必有

$$\lambda \mathbf{x}^{(1)} + (1 - \lambda) \mathbf{x}^{(2)} \in S$$

则称 S 为凸集.

规定单点集 $\{\mathbf{x}\}$ 和空集 \emptyset 都是空集. 需要注意的是, 方程 $\mathbf{x} = \lambda \mathbf{x}^{(1)} + (1 - \lambda) \mathbf{x}^{(2)} = \mathbf{x}^{(2)} + \lambda(\mathbf{x}^{(1)} - \mathbf{x}^{(2)})$, $\lambda \in [0, 1]$ 表示连接 $\mathbf{x}^{(1)}$ 和 $\mathbf{x}^{(2)}$ 的线段.

例 1.2 设 $A \in \mathbb{R}^{m \times n}$, $\mathbf{b} \in \mathbb{R}^n$, 证明以下命题成立:

- (1) 集合 $S = \{\mathbf{x} \mid A\mathbf{x} = \mathbf{b}\}$ 是凸集;
- (2) 集合 $S = \{\mathbf{x} \mid A\mathbf{x} \leq \mathbf{b}\}$ 是凸集.

在介绍凸集的性质之前, 我们先对一些将要用到的名词进行必要的说明.

定义 1.11 (内点、内点集、开集)

设 $S \subseteq \mathbb{R}^n$, $\mathbf{x} \in S$, 如果存在一个开球 $B(\mathbf{x}, \varepsilon) = \{\mathbf{y} \in \mathbb{R}^n \mid \|\mathbf{y} - \mathbf{x}\| < \varepsilon\}$, 使得 $B(\mathbf{x}, \varepsilon) \subseteq S$, 则称 \mathbf{x} 是 S 的内点, S 的内点的全体称为 S 的内点集, 记作 $\text{int}(S)$.

进一步地, 如果 $\text{int}(S) = S$, 则称 S 是开集

所以 $\mathbf{x} \in \text{int}(S) \Leftrightarrow \exists \varepsilon > 0, (\|\mathbf{y} - \mathbf{x}\| < \varepsilon \Rightarrow \mathbf{y} \in S)$.

定义 1.12 (聚点、闭包)

设 $S \subseteq \mathbb{R}^n$, $\mathbf{x} \in \mathbb{R}^n$, 如果 $\forall \varepsilon > 0$ 都有 $B(\mathbf{x}, \varepsilon) \cap S \neq \emptyset$, 则称 \mathbf{x} 是 S 的聚点, S 的聚点的全体称为 S 的闭包, 记作 \bar{S} .

定义 1.13 (超平面)

设 $\boldsymbol{\alpha} \in \mathbb{R}^n \setminus \{0\}$, $\beta \in \mathbb{R}$, 称集合 $H = \{\mathbf{x} \in \mathbb{R}^n \mid \boldsymbol{\alpha}^\top \mathbf{x} = \beta\}$ 是超平面, 简记作 $H: \boldsymbol{\alpha}^\top \mathbf{x} = \beta$.

定义 1.14 (支撑超平面)

设 $S \subseteq \mathbb{R}^n$, $\mathbf{x}_0 \in S$, 若超平面 $H: \boldsymbol{\alpha}^\top \mathbf{x} = \beta$ 满足:

- (i) $\exists \mathbf{x}^{(0)} \in S$, 使得 $\mathbf{x}^{(0)} \in H$;
- (ii) $\forall \mathbf{x} \in S, \boldsymbol{\alpha}^\top \mathbf{x} \leq \beta$

则称 H 是 S 的支撑超平面.

定义 1.15 (分离超平面)

设 $S_1, S_2 \subseteq \mathbb{R}^n$, 且 $S_1 \cap S_2 = \emptyset$. 若存在超平面 $H: \alpha^\top x = \beta$, 使得 $\forall x^{(1)} \in S_1, \alpha^\top x^{(1)} \geq \beta$, 且 $\forall x^{(2)} \in S_2, \alpha^\top x^{(2)} \leq \beta$, 则称 H 是 S_1, S_2 的分离超平面.

定理 1.9 (凸集的性质)

凸集有以下性质:

- (1) 凸集的交是凸集;
- (2) 凸集的内点集是凸集;
- (3) 凸集的闭包是凸集;
- (4) 凸集边界上任意点存在支撑超平面;
- (5) 两个互相不交的凸集之间存在分离超平面.

定义 1.16 (凸组合)

设 $x^{(1)}, x^{(2)}, \dots, x^{(m)} \in \mathbb{R}^n$. 若 $\forall j \in \{1, 2, \dots, m\}, \lambda_j \geq 0$ 且 $\sum_{j=1}^m \lambda_j = 1$, 则称 $\sum_{j=1}^m \lambda_j x^{(j)}$ 为 $x^{(1)}, x^{(2)}, \dots, x^{(m)}$ 的凸组合.

定理 1.10 (凸集和凸组合的关系)

S 是凸集 $\Leftrightarrow S$ 中任意有限点的凸组合属于 S .

定义 1.17 (凸包)

设非空集合 $S \subseteq \mathbb{R}^n$, 由 S 中所有有限点的凸组合所构成的集合, 被称为 S 的凸包, 记作 $\text{cov}(S)$.

定理 1.11 (凸集和凸包的关系)

如果 S 是凸集, 那么 $\text{cov}(S) = S$.

定义 1.18 (多胞形)

设 $x^{(1)}, x^{(2)}, \dots, x^{(m)} \in \mathbb{R}^n$. 由 $x^{(1)}, x^{(2)}, \dots, x^{(m)}$ 的所有凸组合构成的集合称为多胞形, 记作 $H(x^{(1)}, x^{(2)}, \dots, x^{(m)})$.

定义 1.19 (单纯形)

设 $x^{(1)}, x^{(2)}, \dots, x^{(m)} \in \mathbb{R}^n$. 若多胞形 $H(x^{(1)}, x^{(2)}, \dots, x^{(m)})$ 满足 $x^{(2)} - x^{(1)}, x^{(3)} - x^{(1)}, \dots, x^{(m)} - x^{(1)}$ 线性无关, 则称该多胞形是单纯形.

2. 凸锥、半正组合

定义 1.20 (锥、凸锥)

设 $S \subseteq \mathbb{R}^n$, 若 $\forall \mathbf{x} \in S, \lambda > 0$, 必有 $\lambda \mathbf{x} \in S$, 则称 S 为以 0 为顶点的**锥**. 若 S 还是凸集, 则称 S 为**凸锥**.

规定 $\{0\}, \mathbb{R}^n$ 都是凸锥. 锥不一定包含 0.

定义 1.21 (半正组合)

设 $\mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots, \mathbf{x}^{(m)} \in \mathbb{R}^n$. 若 $\forall j \in \{1, 2, \dots, m\}, \lambda_j \geq 0$ 且 $\sum_{j=1}^m \lambda_j > 0$, 则称 $\sum_{j=1}^m \lambda_j \mathbf{x}^{(j)}$ 为 $\mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots, \mathbf{x}^{(m)}$ 的**半正组合**.

定理 1.12 (凸锥和半正组合的关系)

S 是凸锥 $\Leftrightarrow S$ 中任意有限点的半正组合属于 S .

1.5.2 凸函数

1. 凸函数

定义 1.22 (凸函数)

设集合 $S \subseteq \mathbb{R}^n$ 为凸集, 函数 $f: S \rightarrow \mathbb{R}$. 若 $\forall \mathbf{x}^{(1)}, \mathbf{x}^{(2)} \in S, \lambda \in (0, 1)$, 均有

$$f(\lambda \mathbf{x}^{(1)} + (1 - \lambda) \mathbf{x}^{(2)}) \leq \lambda f(\mathbf{x}^{(1)}) + (1 - \lambda) f(\mathbf{x}^{(2)})$$

则称 $f(\mathbf{x})$ 为凸集 S 上的**凸函数**.

若进一步有上面不等式以严格不等式成立, 则称 $f(\mathbf{x})$ 为凸集 S 上的**严格凸函数**. 当 $-f(\mathbf{x})$ 为凸函数 (严格凸函数时), 则称 $f(\mathbf{x})$ 为**凹函数** (**严格凹函数**).

定理 1.13 (Jensen 不等式)

$f(\mathbf{x})$ 为凸集 S 上的凸函数的充要条件是 S 上任意有限点的凸组合的函数值不大于各点函数值的凸组合, 即 $\forall \mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots, \mathbf{x}^{(m)} \in S$, 对于任意的序列 $\{\lambda_j\}_{j=1}^m$ 满足 $\forall j \in \{1, 2, \dots, m\}, \lambda_j \geq 0$ 且 $\sum_{j=1}^m \lambda_j = 1$, 都有

$$f\left(\sum_{j=1}^m \lambda_j \mathbf{x}^{(j)}\right) \leq \sum_{j=1}^m \lambda_j f(\mathbf{x}^{(j)})$$

例 1.3 设 f_1, f_2 是凸函数, 判断:

- (1) 设 $\lambda_1, \lambda_2 > 0$, $\lambda_1 f_1 + \lambda_2 f_2$ 是否为凸函数? $\lambda_1 f_1 - \lambda_2 f_2$ 是否为凸函数?
- (2) $f(\mathbf{x}) = \max\{f_1(\mathbf{x}), f_2(\mathbf{x})\}$ 是否为凸函数? $g(\mathbf{x}) = \min\{f_1(\mathbf{x}), f_2(\mathbf{x})\}$ 是否为凸函数?

定理 1.14 (凸函数的性质)

设 $S \subseteq \mathbb{R}^n$ 为非空凸集, 函数 $f: S \rightarrow \mathbb{R}$, 则有:

- (1) 若 f 是凸函数, 则 f 在 $\text{int}(S)$ 上连续;
- (2) 若 f 是凸函数, 则其对任意方向的方向导数 (若方向可行) 存在;
- (3) 设 S 是开集, f 在 S 上可微, 则 f 是凸函数的充要条件是 $\forall \mathbf{x}^* \in S$, 都有

$$f(\mathbf{x}) \geq f(\mathbf{x}^*) + \nabla f^\top(\mathbf{x}^*)(\mathbf{x} - \mathbf{x}^*)$$

$\forall \mathbf{x} \in S$ 都成立. 进一步地, 如果 f 是严格凸函数, 则其充要条件是上述不等式的严格不等式成立;

- (4) 设 S 是开集, f 在 S 上二次可微, 则:
 - (i) f 是凸函数的充要条件是 $\forall \mathbf{x} \in S$, $\nabla^2 f(\mathbf{x})$ 是半正定的;
 - (ii) 若 $\forall \mathbf{x} \in S$, $\nabla^2 f(\mathbf{x})$ 是正定的, 则 f 是严格凸函数.

例 1.4 若 $f(x) = \begin{cases} 2, & x = \pm 1, \\ x^2, & -1 < x < 1 \end{cases}$, 容易验证 f 是凸函数, 但是 f 在边界点上不连续.

2. 水平集**定义 1.23 (水平集)**

设集合 $S \subseteq \mathbb{R}^n$, 函数 $f: S \rightarrow \mathbb{R}$, $\alpha \in \mathbb{R}$, 称 $S_\alpha = \{\mathbf{x} \in S \mid f(\mathbf{x}) \leq \alpha\}$ 为 $f(\mathbf{x})$ 在 S 上的 α 水平集.

水平集的概念相当于在地形图中, 海拔高度不高于某一数值的区域.

定理 1.15 (凸函数的水平集是凸集)

设集合 $S \subseteq \mathbb{R}^n$ 是凸集, 函数 $f: S \rightarrow \mathbb{R}$ 是凸函数, 则对 $\forall \alpha \in \mathbb{R}$, S_α 是凸集.

上述定理的逆不真.

例 1.5 考虑分段函数 $f(x) = \begin{cases} 1, & x \geq 0, \\ 0, & x < 0 \end{cases}$, 函数非凸, 但其任意水平集是凸集.

1.5.3 凸规划**定义 1.24 (凸规划)**

- (1) 若 (f, S) 中的 S 为凸集, f 是 S 上的凸函数, 优化目标为 \min 时, 则称 (f, S) 为凸规划;
- (2) 若 (f, gh) 中的 f, g_i 为凸函数, h_j 为线性函数, 则称 (f, gh) 为凸规划.

定理 1.16 (凸优化的最优解)

设 (f, S) 为凸优化. 若 \mathbf{x}^* 为问题 (f, S) 的 l.opt., 则 \mathbf{x}^* 为 g.opt. 进一步地, 若 f 是严格凸函数, 则 \mathbf{x}^* 是 (f, S) 的唯一 g.opt.

1.6 多面体、极点、极方向

定义 1.25 (半空间)

设超平面 $H: \alpha^\top x = \beta \subseteq \mathbb{R}^n$, 则这个超平面把 \mathbb{R}^n 分成两部分 $\{x \in \mathbb{R}^n \mid \alpha^\top x \geq \beta\}$ 和 $\{x \in \mathbb{R}^n \mid \alpha^\top x \leq \beta\}$, 这样的两部分称为闭半空间, 若有严格不等式成立, 则称其为开半空间.

定义 1.26 (多面体)

有限个闭半空间的交称为多面体.

由定义看出, 多面体实际上由一系列线性不等式组定义, 故一般可以将其写作 $\{x \in \mathbb{R}^n \mid Ax \leq b\}$, 其中 $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$. 其中我们选取一种特殊的多面体 $\{x \in \mathbb{R}^n \mid Ax = b, x \geq 0\}$, 称其为标准型多面体.

定义 1.27 (极点)

设 $S \subseteq \mathbb{R}^n$, $x \in S$, 若不存在 $x^{(1)}, x^{(2)} \in S$, $x^{(1)} \neq x^{(2)}$, 使得 $x = \lambda x^{(1)} + (1 - \lambda)x^{(2)}$, 则称 x 是 S 的极点 (或顶点).

定义 1.28 (极方向)

设 $S \subseteq \mathbb{R}^n$, $d \in \mathbb{R}^n$, 若 d 是 S 的可行方向 (见方向导数的定义), 且不能被表示为 S 的两个不同可行方向的非负组合, 则称 d 是 S 的极方向.

定理 1.17 (极点特征)

设多面体 $S = \{x \in \mathbb{R}^n \mid Ax = b, x \geq 0\}$, 其中 $A \in \mathbb{R}^{m \times n}$ 行满秩, 则 x 是多面体 S 的极点的充要条件是存在分解 $A = (B, N)$, 使得

- (i) B 为 m 阶可逆阵;
- (ii) $x = (x_B^\top, x_N^\top)^\top$ (分解方式与 A 相同), 其中 $x_B = B^{-1}b \geq 0$, $x_N = 0$.

例 1.6 证明: 多面体 $S = \{x \in \mathbb{R}^n \mid Ax = b, x \geq 0\}$ 中必存在有限多的极点.

例 1.7 设多面体 $S = \{x \in \mathbb{R}^n \mid Ax = b, x \geq 0\}$, 在以下条件下, 求该多面体的极点:

- (1) $A = \begin{pmatrix} 3 & 1 & 2 & 0 \\ 0 & 4 & 5 & 1 \end{pmatrix}, b = \begin{pmatrix} 3 \\ 6 \end{pmatrix};$
- (2) $A = \begin{pmatrix} 3 & 2 & 1 & 0 & 0 \\ 2 & 1 & 0 & 1 & 0 \\ 0 & 3 & 0 & 0 & 1 \end{pmatrix}, b = \begin{pmatrix} 65 \\ 40 \\ 75 \end{pmatrix}.$

定理 1.18 (极方向特征)

设多面体 $S = \{x \in \mathbb{R}^n \mid Ax = b, x \geq 0\}$, 其中 $A \in \mathbb{R}^{m \times n}$ 行满秩, 则

(1) d 是 S 的方向的充要条件是 $Ad = 0$ 且 $d \geq 0$;

(2) d 是 S 的极方向的充要条件是存在分解 $A = (B, N)$, 使得

(i) B 为 m 阶可逆阵;

(ii) $d = (d_B^T, d_N^T)^T$ (分解方式与 A 相同), 其中 $d_B = -B^{-1}a_j \geq 0$, $d_N = e_j$. 这里 e_j 是第 j 个元素为 1, 其余元素为 0 的单位向量. j 是使得 N 中的列向量 a_j 满足 $B^{-1}a_j \leq 0$ 的下标.

例 1.8 证明: 多面体 $S = \{x \in \mathbb{R}^n \mid Ax = b, x \geq 0\}$ 中必有极点, 且个数不超过 $(n-m)C_n^m$.

例 1.9 设多面体 $S = \{x \in \mathbb{R}^n \mid Ax = b, x \geq 0\}$, 其中 $A = \begin{pmatrix} 3 & 1 & 2 & -6 & 0 \\ 0 & 4 & 5 & -5 & 1 \end{pmatrix}, b = \begin{pmatrix} 3 \\ 6 \end{pmatrix}$, 求

该多面体的极方向.

定理 1.19 (表示定理, Minkowski-Weyl)

设多面体 $S = \{x \in \mathbb{R}^n \mid Ax = b, x \geq 0\}$, 其中 $A \in \mathbb{R}^{m \times n}$ 行满秩, $x^{(1)}, x^{(2)}, \dots, x^{(k)}$ 为所有极点, $d^{(1)}, d^{(2)}, \dots, d^{(l)}$ 为所有极方向, 则 $\forall x \in S$, 存在序列 $\{\lambda_i\}_{i=1}^k, \{\mu_j\}_{j=1}^l$, 其中:

(1) $\lambda_i > 0, i = 1, 2, \dots, k$, 且 $\sum_{i=1}^k \lambda_i = 1$;

(2) $\mu_j \geq 0, j = 1, 2, \dots, l$, 使得

$$x = \lambda_1 x^{(1)} + \lambda_2 x^{(2)} + \dots + \lambda_k x^{(k)} \quad (\text{极点的凸组合})$$

$$+ \mu_1 d^{(1)} + \mu_2 d^{(2)} + \dots + \mu_l d^{(l)} \quad (\text{极方向的半正组合})$$

特别地, 如果上述多面体 S 是有界的, 则有 $\mu_j = 0$.

第二章 线性规划

2.1 线性规划模型

2.1.1 线性规划的定义

我们先来介绍线性规划的一般形式.

定义 2.1 (线性规划的一般形式)

线性规划的一般形式如下:

$$\begin{aligned}
 \max(\min) \quad & z = c_1x_1 + c_2x_2 + \cdots + c_nx_n \\
 \text{s.t.} \quad & a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n \leq (=, \geq) b_1 \\
 & a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n \leq (=, \geq) b_2 \\
 & \vdots \\
 & a_{m1}x_1 + a_{m2}x_2 + \cdots + a_{mn}x_n \leq (=, \geq) b_m \\
 & x_1, x_2, \cdots, x_n \in \mathbb{R}
 \end{aligned}$$

其中, 称 c_i 为目标函数系数或价值系数或费用系数; 称 b_j 为右端项或资源常数; 称 a_{ij} 为约束系数或技术系数.

我们为了方便解决问题, 常把上述一般形式转化为标准形式:

定义 2.2 (线性规划的标准形式)

线性规划的标准形式如下:

$$\begin{aligned}
 \max \quad & z = c_1x_1 + c_2x_2 + \cdots + c_nx_n \\
 \text{s.t.} \quad & a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n = b_1 \\
 & a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n = b_2 \\
 & \vdots \\
 & a_{m1}x_1 + a_{m2}x_2 + \cdots + a_{mn}x_n = b_m \\
 & x_1, x_2, \cdots, x_n \geq 0
 \end{aligned}$$

其中右端项 $b_1, b_2, \cdots, b_m \geq 0$.

为了研究问题的方便，我们将其写成矩阵形式

$$\max \quad z = \mathbf{c}^\top \mathbf{x}$$

$$\text{s.t.} \quad \mathbf{Ax} = \mathbf{b}$$

$$\mathbf{x} \geq 0$$

其中， $\mathbf{c}, \mathbf{x} \in \mathbb{R}^n$ ， $\mathbf{b} \geq 0$ ， $\mathbf{A} \in \mathbb{R}^{m \times n}$. 线性规划的标准形式记作 (LP).

定义 2.3 (线性规划的规范形式)

线性规划的规划形式如下：

$$\max \quad z = \mathbf{c}^\top \mathbf{x}$$

$$\text{s.t.} \quad \mathbf{Ax} \leq \mathbf{b}$$

$$\mathbf{x} \geq 0$$

其中， $\mathbf{c}, \mathbf{x} \in \mathbb{R}^n$ ， $\mathbf{b} \geq 0$ ， $\mathbf{A} \in \mathbb{R}^{m \times n}$.

线性规划的规范形式记作 (P).

不难发现，标准形式有区别于一般形式的以下四个特点：

- 目标最大化；
- 约束为等式；
- 决策变量均非负；
- 右端项非负.

接下来我们将会讨论如何将一般形式一步步转化为标准形式.

2.1.2 将一般形式转化为标准形式

1. 极小目标极大化

在标准形式中，要求优化目标为极大化目标函数值. 若目标函数为

$$\min f = c_1x_1 + c_2x_2 + \cdots + c_nx_n$$

则令 $z = -f$ ，从而上述极小化问题与下面的极大化问题

$$\max z = -c_1x_1 - c_2x_2 - \cdots - c_nx_n$$

有相同的最优解，但它们的最优解的目标函数值相差一个符号，即

$$\min f = -\max z$$

2. 约束条件不为等式

在标准形式中，要求每约束条件均为等式. 若约束条件为小于等于号，即设第 i 个约束条件为

$$a_{i1}x_1 + a_{i2}x_2 + \cdots + a_{in}x_n \leq b_i$$

则可以引入一个松弛变量 s , 使得

$$s = b_i - (a_{i1}x_1 + a_{i2}x_2 + \cdots + a_{in}x_n)$$

从而 $s \geq 0$, 也具有非负约束, 这时新的约束条件成为

$$a_{i1}x_1 + a_{i2}x_2 + \cdots + a_{in}x_n + s = b_i$$

若约束条件为大于等于号, 即设第 i 个约束条件为

$$a_{i1}x_1 + a_{i2}x_2 + \cdots + a_{in}x_n \geq b_i$$

相似地, 也可以引入一个松弛变量 s , 使得

$$s = (a_{i1}x_1 + a_{i2}x_2 + \cdots + a_{in}x_n) - b_i$$

从而 $s \geq 0$, 也具有非负约束, 这时新的约束条件成为

$$a_{i1}x_1 + a_{i2}x_2 + \cdots + a_{in}x_n - s = b_i$$

3. 变量无符号限制

在标准形式中, 要求每一个变量均有非负约束. 当某一个变量 x_j 没有非负约束时, 可以令

$$x_j = x'_j - x''_j$$

其中 $x'_j, x''_j \geq 0$, 即用两个非负数之差表示一个无符号限制的变量.

4. 右端项有负值

在标准形式中, 要求每一个约束条件右端均为正值. 当某一个右端项系数为负时, 假设是第 i 个, 即

$$a_{i1}x_1 + a_{i2}x_2 + \cdots + a_{in}x_n = b_i \leq 0$$

则把该等式两端同时乘以 -1 , 得到

$$-a_{i1}x_1 - a_{i2}x_2 - \cdots - a_{in}x_n = -b_i \geq 0$$

例 2.1 将以下线性规划问题转化为标准形式.

$$(1) \min f = 3.6x_1 - 5.2x_2 + 1.8x_3$$

$$\text{s.t. } 2.3x_1 + 5.2x_2 - 6.1x_3 \leq 15.7$$

$$4.1x_1 + 3.3x_3 \geq 8.9$$

$$x_1 + x_2 + x_3 = 38$$

$$x_1, x_2, x_3 \geq 0$$

$$\begin{aligned} (2) \quad & \min \quad f = -3x_1 + 5x_2 + 8x_3 - 7x_4 \\ & \text{s.t.} \quad 2x_1 - 3x_2 + 5x_3 + 6x_4 \leq 28 \\ & \quad \quad 4x_1 + 2x_2 + 3x_3 - 9x_4 \geq 39 \\ & \quad \quad 6x_2 + 2x_3 + 3x_4 \leq -58 \\ & \quad \quad x_1, x_2, x_3 \geq 0 \end{aligned}$$

2.2 线性规划的单纯形法

2.2.1 线性规划理论

线性规划的单纯形法依托以下一个定理：

定理 2.1 （解的存在性）

考虑 (LP) 和多面体 $S = \{x \in \mathbb{R}^n \mid Ax = b, x \geq 0\}$ ，设 A 满秩， $x^{(1)}, x^{(2)}, \dots, x^{(k)}$ 为所有极点， $d^{(1)}, d^{(2)}, \dots, d^{(l)}$ 为所有极方向，则

- (1) (LP) 存在有界最优解 $\Leftrightarrow c^T d^{(j)} \leq 0, \forall j = 1, 2, \dots, l$;
- (2) 若 (LP) 存在有界最优解，则最优解可以在某个极点得到。

由此，我们可以得到，我们要求 (LP) 的最优解，只要求多面体有限个极点的函数值即可。看上去问题似乎是解决了，但是极点的个数大致随着多面体的维数成指数级增加（参考例题 1.8）！此外，求取极点的过程伴随着矩阵的求逆，而这是非常昂贵的。所以我们需要一个有选择的迭代算法代替枚举算法。

在进行相关讨论之前，由于原 ppt 和书中的概念过于杂乱，笔者认为有必要将线性规划相关的基础概念总结如下：

定义 2.4 （线性规划相关概念）

(1) **基**：对于线性规划的约束条件 $Ax = b, x \geq 0$ ，设 B 是矩阵 A 中的一个可逆的 $m \times m$ 的子矩阵，则称 B 为线性规划的一个**基矩阵**，简称**基**，称 N 为基矩阵 B 对应的**非基矩阵**；

(2) **基变量、非基变量**：对应于基 B 中列向量 $a_{j_1}, a_{j_2}, \dots, a_{j_m}$ 的变量 $x_{j_1}, x_{j_2}, \dots, x_{j_m}$ 称为**基变量**，其他变量（即对应于非基矩阵 N 中列向量的变量）称为**非基变量**；

(3) **基本解、基本可行解、可行基**：令所有非基变量为 0，可以得到 m 个关于基变量 $x_{j_1}, x_{j_2}, \dots, x_{j_m}$ 的线性方程组，解这个线性方程组得到基变量的值，称如上得到的解为一个**基本解**；若得到的基变量的值均非负，则称其为**基本可行解**，称这个基 B 为**可行基**。写成矩阵形式，

$$x = \begin{pmatrix} x_B \\ x_N \end{pmatrix} = \begin{pmatrix} B^{-1}b \\ 0 \end{pmatrix}$$

称为线性规划问题的一个**基本可行解**。

显然必有以下定理成立：

定理 2.2 （线性规划基本定理）

线性规划的基本可行解就是可行域的极点。

下面的定理表明了我们不需要将所有的极点都代入目标函数，也可以精确地求出最优解

opt..

定理 2.3 (最优性定理)

考虑 (LP)，条件同上，设 \mathbf{x}^* 为极点，存在基分解 $\mathbf{A} = (\mathbf{B}, \mathbf{N})$ ，其中 \mathbf{B} 为 m 阶可逆矩阵，使 $\mathbf{x}^* = (\mathbf{x}_B^{*\top}, \mathbf{x}_N^{*\top})^\top$ ，此处分解与 \mathbf{A} 相同，且 $\mathbf{x}_B^* = \mathbf{B}^{-1}\mathbf{b} \geq 0$ ， $\mathbf{x}_N^* = 0$ 。相应 $\mathbf{c}^\top = (\mathbf{c}_B^\top, \mathbf{c}_N^\top)^\top$ ，则

(1) 若 $\mathbf{c}_N^\top - \mathbf{c}_B^\top \mathbf{B}^{-1} \mathbf{N} \leq 0$ ，则 \mathbf{x}^* 为 opt.；

(2) 若存在属于 \mathbf{N} 的分量 j ，使得 $\mathbf{c}_j - \mathbf{c}_B^\top \mathbf{B}^{-1} \mathbf{a}_j > 0$ ，且 $\mathbf{B}^{-1} \mathbf{a}_j \leq 0$ ，则 (LP) 无有界解。

2.2.2 表格单纯形法原理及算法原理

让我们回忆线性规划的标准形式如下

$$\begin{aligned} \max \quad & z = \mathbf{c}^\top \mathbf{x} \\ \text{(LP)} \quad & \text{s.t. } \mathbf{A}\mathbf{x} = \mathbf{b} \\ & \mathbf{x} \geq 0 \end{aligned}$$

其中， $\mathbf{c}, \mathbf{x} \in \mathbb{R}^n$ ， $\mathbf{b} \in \mathbb{R}^m$ ， \mathbf{A} 为 $m \times n$ 行满秩矩阵，即 $\text{rank}(\mathbf{A}) = m$ 。

1. 单纯形法原理及算法过程

下边的算法介绍了单纯形法求线性规划最优解的过程。

算法 1: 单纯形法迭代算法 (Simplex Method)

输入 : 系数矩阵 $\mathbf{A} \in \mathbb{R}^{m \times n}$ ，向量 $\mathbf{b} \in \mathbb{R}^m$ ，价值向量 $\mathbf{c} \in \mathbb{R}^n$

输出 : 最优解 \mathbf{x}^* 或问题无界结论

初始化: 已知极点 $\mathbf{x}^{(k)}$ ，基分解 $\mathbf{A} = (\mathbf{B}, \mathbf{N})$ ，满足 $\mathbf{x}_B^{(k)} = \mathbf{B}^{-1}\mathbf{b} \geq 0$ ， $\mathbf{x}_N^{(k)} = 0$

2: 计算检验向量: $\boldsymbol{\sigma}_N^\top = \mathbf{c}_N^\top - \mathbf{c}_B^\top \mathbf{B}^{-1} \mathbf{N}$;

4: **if** $\boldsymbol{\sigma}_N \leq 0$ **then**

5: **return** $\mathbf{x}^{(k)}$ 为 opt.;

7: 选择进基变量索引 j 使得 $\sigma_j > 0$;

9: **if** $\mathbf{B}^{-1} \mathbf{a}_j \leq 0$ **then**

10: **return** 问题无有界解;

12: **else**

13: 计算步长 $\alpha = \min \left\{ \frac{(\mathbf{B}^{-1} \mathbf{b})_i}{(\mathbf{B}^{-1} \mathbf{a}_j)_i} \mid (\mathbf{B}^{-1} \mathbf{a}_j)_i > 0 \right\} = \frac{(\mathbf{B}^{-1} \mathbf{b})_r}{(\mathbf{B}^{-1} \mathbf{a}_j)_r}$;

14: 更新解向量: $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha \mathbf{d}$;

15: 其中 $\mathbf{d}^\top = (\mathbf{d}_B^\top, \mathbf{d}_N^\top)$ ，且 $\mathbf{d}_B = -\mathbf{B}^{-1} \mathbf{a}_j$ ， $\mathbf{d}_N = \mathbf{e}_j$;

17: 更新基矩阵 \mathbf{B} 为 \mathbf{B}' ，令 $k \leftarrow k + 1$ 并返回步骤 1;

为了说明这个算法的合理性, 我们需要说明以下两点成立:

定理 2.4

上述算法中, 更新点 $\mathbf{x}^{(k+1)}$

- (1) 是更优的;
- (2) 也是 S 的一个极点.

2. 单纯形表

设 \mathbf{x} 为初始极点, 相应分解 $\mathbf{A} = (\mathbf{B}, \mathbf{N})$, 则列单纯形表如下:

| | f | \mathbf{x}_B^\top | \mathbf{x}_N^\top | RHS | |
|-----|-----|---------------------|---------------------|--------------|-------|
| 目标行 | 1 | \mathbf{c}_B^\top | \mathbf{c}_N^\top | 0 | 1 行 |
| 约束行 | 0 | \mathbf{B} | \mathbf{N} | \mathbf{b} | m 行 |
| | 1 列 | m 行 | $n - m$ 行 | 1 列 | |

作变换, 使前 $m + 1$ 列对应的 $m + 1$ 阶矩阵变为单位矩阵, 相当于该表左乘 $\begin{pmatrix} 1 & \mathbf{c}_B^\top \\ 0 & \mathbf{B} \end{pmatrix}^{-1} = \begin{pmatrix} 1 & -\mathbf{c}_B^\top \mathbf{B}^{-1} \\ 0 & \mathbf{B}^{-1} \end{pmatrix}$. 消去方法为 Gauss 主元消去法. 于是得到

| | f | \mathbf{x}_B^\top | \mathbf{x}_N^\top | RHS | |
|-----|-----|---------------------|--|---|-------|
| 目标行 | 1 | 0^\top | $\mathbf{c}_N^\top - \mathbf{c}_B^\top \mathbf{B}^{-1} \mathbf{N}$ | $-\mathbf{c}_B^\top \mathbf{B}^{-1} \mathbf{b}$ | 1 行 |
| 约束行 | 0 | \mathbf{I} | $\mathbf{B}^{-1} \mathbf{N}$ | $\mathbf{B}^{-1} \mathbf{b}$ | m 行 |
| | 1 列 | m 行 | $n - m$ 行 | 1 列 | |

根据算法内容, 令检验向量 $\boldsymbol{\sigma}_N^\top = \mathbf{c}_N^\top - \mathbf{c}_B^\top \mathbf{B}^{-1} \mathbf{N}$, 则单纯形表转化为

| | f | \mathbf{x}_B^\top | \mathbf{x}_N^\top | RHS | |
|-----|-----|---------------------|------------------------------|--------------------------------------|-------|
| 目标行 | 1 | 0^\top | $\boldsymbol{\sigma}^\top$ | $-z = -\mathbf{c}^\top \mathbf{x}^*$ | 1 行 |
| 约束行 | 0 | \mathbf{I} | $\mathbf{B}^{-1} \mathbf{N}$ | \mathbf{x}_B^* | m 行 |
| | 1 列 | m 行 | $n - m$ 行 | 1 列 | |

可是我们知道, 对矩阵求逆的代价是十分昂贵的 (对一个 n 阶矩阵求逆的时间复杂度为 $O(n^3)$)

. 所以如果我们能使 $\mathbf{B} = \mathbf{I}$, 则 $\mathbf{B}^{-1} = \mathbf{I}$, 此时求矩阵 \mathbf{B} 的逆将会很简单, 此时

| | f | \mathbf{x}_B^\top | \mathbf{x}_N^\top | RHS | |
|-----|-----|---------------------|--|---------------------------------|-------|
| 目标行 | 1 | 0^\top | $\mathbf{c}_N^\top - \mathbf{c}_B^\top \mathbf{N}$ | $-\mathbf{c}_B^\top \mathbf{b}$ | 1 行 |
| 约束行 | 0 | \mathbf{I} | \mathbf{N} | \mathbf{b} | m 行 |
| | 1 列 | m 行 | $n - m$ 行 | 1 列 | |

综上所述，我们将单次迭代所需要用到的所有元素集中在一张表中，就得到了如下经过改造的单纯形表：（其中，表??对矩阵 \mathbf{B} 不作除可逆外的任何要求，表??中令 $\mathbf{B} = \mathbf{I}$ ）

表 2.1: 经过改造后的单纯形表

| \mathbf{c}_B | \mathbf{x}_B | \mathbf{b} | \mathbf{c}_B^\top | \mathbf{c}_N^\top | α |
|----------------|----------------|--|---------------------|---|----------|
| | | | \mathbf{x}_B^\top | \mathbf{x}_N^\top | |
| * | * | $\mathbf{B}^{-1}\mathbf{b}$ | \mathbf{I} | $\mathbf{B}^{-1}\mathbf{N}$ | * |
| $-z$ | | $-\mathbf{c}_B^\top \mathbf{B}^{-1}\mathbf{b}$ | 0^\top | $\mathbf{c}_N^\top - \mathbf{c}_B^\top \mathbf{B}^{-1}\mathbf{N}$ | |

表 2.2: 经过改造后的单纯形表（令 $\mathbf{B} = \mathbf{I}$ ）

| \mathbf{c}_B | \mathbf{x}_B | \mathbf{b} | \mathbf{c}_B^\top | \mathbf{c}_N^\top | α |
|----------------|----------------|---------------------------------|---------------------|--|----------|
| | | | \mathbf{x}_B^\top | \mathbf{x}_N^\top | |
| * | * | \mathbf{b} | \mathbf{I} | \mathbf{N} | * |
| $-z$ | | $-\mathbf{c}_B^\top \mathbf{b}$ | 0^\top | $\mathbf{c}_N^\top - \mathbf{c}_B^\top \mathbf{N}$ | |

该表的填写规则如下：（合并的单元格按照合并之前最左上角的单元格编号）

- 表格第 3 行第 1-2 列（即 \mathbf{c}_B 和 \mathbf{x}_B 所示单元格下边的单元格），将列向量 $\mathbf{c}_B, \mathbf{x}_B$ 分别展开后写入；

- 表格第 3 行第 3 列（即 $\mathbf{B}^{-1}\mathbf{b}$ 或 \mathbf{b} 所示单元格），将列向量 $\mathbf{B}^{-1}\mathbf{b}$ 或 \mathbf{b} 展开后写入；

- 表格第 4 行第 3 列（即 $-\mathbf{c}_B^\top \mathbf{B}^{-1}\mathbf{b}$ 或 $-\mathbf{c}_B^\top \mathbf{b}$ 所示单元格），将标量 $-\mathbf{c}_B^\top \mathbf{B}^{-1}\mathbf{b}$ 或 $-\mathbf{c}_B^\top \mathbf{b}$ 计算出来后写入；

- 表格第 4-5 列，将所示行向量或矩阵展开后写入；

- 表格第 3 行第 6 列（即 α 所示单元格下边的单元格），将列向量 α 展开后写入. 其中，

$$\text{步长 } \alpha_i = \begin{cases} \frac{b_i}{a_{ik}}, & a_{ik} > 0 \\ \infty, & a_{ik} \leq 0 \end{cases}, \quad k \text{ 为进基变量索引.}$$

3. 引入单位阵 I

这一小节我们分为两种情况来讨论：对**规范形式**求解线性规划问题和**一般情况下的求解**线性规划问题.

考虑线性规划的规范形式 (P)

$$\begin{aligned}
 \max \quad & z = c_1x_1 + c_2x_2 + \cdots + c_nx_n \\
 \text{s.t.} \quad & a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n \leq b_1 \\
 & a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n \leq b_2 \\
 & \vdots \\
 & a_{m1}x_1 + a_{m2}x_2 + \cdots + a_{mn}x_n \leq b_m \\
 & x_1, x_2, \cdots, x_n \geq 0 \\
 & b_1, b_2, \cdots, b_m > 0
 \end{aligned}$$

加入松弛变量 $x_{n+1}, x_{n+2}, \cdots, x_{n+m}$ 后, 转化为标准形式

$$\begin{aligned}
 \max \quad & z = c_1x_1 + c_2x_2 + \cdots + c_nx_n \\
 \text{s.t.} \quad & a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n + x_{n+1} = b_1 \\
 & a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n + x_{n+2} = b_2 \\
 & \vdots \\
 & a_{m1}x_1 + a_{m2}x_2 + \cdots + a_{mn}x_n + x_{n+m} = b_m \\
 & x_1, x_2, \cdots, x_n, x_{n+1}, x_{n+2}, \cdots, x_{n+m} \geq 0 \\
 & b_1, b_2, \cdots, b_m > 0
 \end{aligned}$$

我们可以得到, $x_j = 0, j = 1, 2, \cdots, n; x_{n+i} = b_i, i = 1, 2, \cdots, m$ 是 S 的一个基本可行解, 对应的 B 是单位矩阵.

应用单纯形法解线性规划问题有如下注意事项:

- 每一步运算只能用矩阵初等行变换;
- 表中第 3 列的数总应保持非负;
- 当所有检验数均非正时, 得到最优单纯形表;
- 检验数的更新也相当于是主元消去.

例 2.2 用单纯形法解如下线性规划问题:

$$\begin{aligned}
 (1) \max \quad & z = 1500x_1 + 2500x_2 \\
 \text{s.t.} \quad & 3x_1 + 2x_2 + x_3 = 65 \\
 & 2x_1 + x_2 + x_4 = 40 \\
 & 3x_2 + x_5 = 75 \\
 & x_1, x_2, \cdots, x_5 \geq 0
 \end{aligned}$$

$$\begin{aligned}
 (2) \quad & \max \quad z = 1500x_1 + 1000x_2 \\
 & \text{s.t.} \quad 3x_1 + 2x_2 + x_3 = 65 \\
 & \quad \quad 2x_1 + x_2 + x_4 = 40 \\
 & \quad \quad 3x_2 + x_5 = 75 \\
 & \quad \quad x_1, x_2, \dots, x_5 \geq 0
 \end{aligned}$$

接下来我们讨论一般情况，即初始基本可行解不明显时的情况。

考虑一般问题

$$\begin{aligned}
 \max \quad & z = c_1x_1 + c_2x_2 + \dots + c_nx_n \\
 \text{s.t.} \quad & a_{11}x_1 + a_{12}x_2 + \dots + a_{1n}x_n = b_1 \\
 & a_{21}x_1 + a_{22}x_2 + \dots + a_{2n}x_n = b_2 \\
 & \vdots \\
 & a_{m1}x_1 + a_{m2}x_2 + \dots + a_{mn}x_n = b_m \\
 & x_1, x_2, \dots, x_n \geq 0
 \end{aligned}$$

其中右端项 $b_1, b_2, \dots, b_m \geq 0$ 。接下来介绍两种方法。

大 M 法：

引入人工变量 $x_{n+i} \geq 0$ ， $i = 1, 2, \dots, m$ 及充分大正数 M ，得到

$$\begin{aligned}
 \max \quad & z = c_1x_1 + c_2x_2 + \dots + c_nx_n - Mx_{n+1} - \dots - Mx_{n+m} \\
 \text{s.t.} \quad & a_{11}x_1 + a_{12}x_2 + \dots + a_{1n}x_n + x_{n+1} = b_1 \\
 & a_{21}x_1 + a_{22}x_2 + \dots + a_{2n}x_n + x_{n+2} = b_2 \\
 & \vdots \\
 & a_{m1}x_1 + a_{m2}x_2 + \dots + a_{mn}x_n + x_{n+m} = b_m \\
 & x_1, x_2, \dots, x_n, x_{n+1}, \dots, x_{n+m} \geq 0
 \end{aligned}$$

显然， $x_j = 0$ ， $j = 1, 2, \dots, n$ ； $x_{n+i} = b_i$ ， $i = 1, 2, \dots, m$ 是 S 的一个基本可行解，对应的 \mathbf{B} 是单位矩阵。若得到的最优解满足 $x_{n+i} = 0$ ， $i = 1, 2, \dots, m$ ，则其为原问题的**最优解**；否则，原问题**无可行解**。

例 2.3 应用大 M 法解如下线性规划问题

$$\begin{aligned}
 \max \quad & z = 5x_1 + 2x_2 + 3x_3 - x_4 \\
 \text{s.t.} \quad & x_1 + 2x_2 + 3x_3 = 15 \\
 & 2x_1 + x_2 + 5x_3 = 20 \\
 & x_1 + 2x_3 + 4x_3 + x_4 = 26 \\
 & x_1, x_2, x_3, x_4 \geq 0
 \end{aligned}$$

两阶段法：

两阶段法的核心思想是：先求出原问题的一个基本可行解（第一阶段），再求解原问题（第二阶段）。

第一阶段中，引入人工变量 $x_{n+i} \geq 0$ ， $i = 1, 2, \dots, m$ ，构造：

$$\begin{aligned} \max \quad & z = -x_{n+1} - x_{n+2} - \dots - x_{n+m} \\ \text{s.t.} \quad & a_{11}x_1 + a_{12}x_2 + \dots + a_{1n}x_n + x_{n+1} = b_1 \\ & a_{21}x_1 + a_{22}x_2 + \dots + a_{2n}x_n + x_{n+2} = b_2 \\ & \vdots \\ & a_{m1}x_1 + a_{m2}x_2 + \dots + a_{mn}x_n + x_{n+m} = b_m \\ & x_1, x_2, \dots, x_n, x_{n+1}, \dots, x_{n+m} \geq 0 \end{aligned}$$

之后求解上述问题。显然， $x_j = 0$ ， $j = 1, 2, \dots, n$ ； $x_{n+i} = b_i$ ， $i = 1, 2, \dots, m$ 是 S 的一个基本可行解，对应的 \mathbf{B} 是单位矩阵。若得到的最优解满足 $x_{n+i} = 0$ ， $i = 1, 2, \dots, m$ ，则其为原问题的基本可行解；否则，原问题无可行解。得到原问题的基本可行解之后，求解原问题。

例 2.4 应用两阶段法解如下线性规划问题

$$\begin{aligned} \max \quad & z = 5x_1 + 2x_2 + 3x_3 - x_4 \\ \text{s.t.} \quad & x_1 + 2x_2 + 3x_3 = 15 \\ & 2x_1 + x_2 + 5x_3 = 20 \\ & x_1 + 2x_3 + 4x_3 + x_4 = 26 \\ & x_1, x_2, x_3, x_4 \geq 0 \end{aligned}$$

2.3 线性规划的对偶

2.3.1 对偶问题

我们用下面的例子引出本节的讨论.

设某工厂有 A、B、C 三种类型的设备, 生产甲、乙两种设备. 每件产品在生产中需要占用的设备机时数、每件产品可以获得的利润以及三种设备可利用的机时数如下表所示:

| | 甲产品 | 乙产品 | 设备能力 (h) |
|----------|------|------|----------|
| 设备 A | 3 | 2 | 65 |
| 设备 B | 2 | 1 | 40 |
| 设备 C | 0 | 3 | 75 |
| 利润 (元/件) | 1500 | 2500 | / |

试问:

- (1) 工厂应如何安排生产可获得最大的总利润?
- (2) 若工厂的设备都用于外协加工, 工厂收取加工费. 试问: 设备 A、B、C 每工时各如何收费才最有竞争力?

对于第 (1) 个问题, 设工厂生产 x_1 个甲产品, x_2 个乙产品, 则可列线性规划问题如下:

$$\begin{aligned} \max \quad & z = 1500x_1 + 2500x_2 \\ \text{s.t.} \quad & 3x_1 + 2x_2 \leq 65 \\ & 2x_1 + x_2 \leq 40 \\ & 3x_2 \leq 75 \\ & x_1, x_2 \geq 0 \end{aligned}$$

对于第 (2) 个问题, 设设备 A、B、C 每工时各收费 y_1, y_2, y_3 元, 则可列线性规划问题如下:

$$\begin{aligned} \min \quad & f = 65y_1 + 40y_2 + 75y_3 \\ \text{s.t.} \quad & 3y_1 + 2y_2 \geq 1500 \\ & 2y_1 + y_2 + 3y_3 \geq 2500 \\ & y_1, y_2, y_3 \geq 0 \end{aligned}$$

定义 2.5 (对偶规划)

称具有以下对称形式的两个线性规划问题互为对偶规划:

$$(\text{LP}) \max \quad z = \mathbf{c}^\top \mathbf{x}$$

$$\text{s.t.} \quad \mathbf{Ax} \leq \mathbf{b}$$

$$\mathbf{x} \geq 0$$

$$(\text{DP}) \min \quad f = \mathbf{b}^\top \mathbf{y}$$

$$\text{s.t.} \quad \mathbf{A}^\top \mathbf{y} \geq \mathbf{c}$$

$$\mathbf{y} \geq 0$$

一对对称形式的对偶规划之间具有下面的对应关系^①：

• 若一个模型为目标求“极大”，约束为“小于等于”的不等式，则它的对偶模型为目标求“极小”，约束是“大于等于”的不等式。即“max, ≤”和“min, ≥”相对应；

• 从约束系数矩阵看：一个模型中为 \mathbf{A} ，则另一个模型中为 \mathbf{A}^\top 。一个模型是 m 个约束、 n 个变量，则它的对偶模型为 n 个约束、 m 个变量；

• 从数据 \mathbf{b}, \mathbf{c} 的位置看：在两个规划模型中， \mathbf{b} 和 \mathbf{c} 的位置对换；

• 两个规划模型中的变量皆非负。

对于不满足上述定义形式的线性规划问题，其对偶规划可按如下规则直接给出：

• 将模型统一为“max, ≤”或“min, ≥”的形式；

• 若原规划的某个约束条件为等式约束，则在対偶规划中与此约束对应的变量取值没有非负限制；

• 若原规划的某个变量的值没有非负限制，则在対偶问题中与此变量对应的约束为等式。

例 2.5 写出下面线性规划的对偶规划模型。

$$\max \quad z = x_1 - x_2 + 5x_3 - 7x_4$$

$$\text{s.t.} \quad x_1 + 3x_2 - 2x_3 + x_4 = 25$$

$$2x_1 + 7x_2 + 2x_4 \geq -60$$

$$2x_1 + 2x_2 - 4x_3 \leq 30$$

$$x_1, x_2 \geq 0, -5 \leq x_4 \leq 10$$

2.3.2 对偶定理

定理 2.5（弱对偶定理）

若 \mathbf{x}, \mathbf{y} 分别为 (LP) 和 (DP) 的可行解，那么 $\mathbf{c}^\top \mathbf{x} \leq \mathbf{b}^\top \mathbf{y}$

推论

设 (LP) 有可行解，那么若 (LP) 无有界最优解，则 (DP) 无可行解。

定理 2.6（最优性准则）

若 \mathbf{x}, \mathbf{y} 分别为 (LP) 和 (DP) 的可行解，且 $\mathbf{c}^\top \mathbf{x} = \mathbf{b}^\top \mathbf{y}$ ，那么 \mathbf{x}, \mathbf{y} 分别为 (LP) 和 (DP) 的最优解。

^① \mathbf{c} 换 \mathbf{b} ， \mathbf{x} 换 \mathbf{y} ，约束矩阵变转置。

定理 2.7 (主对偶定理)

若 (LP) 有最优解, 则 (DP) 也有最优解. 反之也成立, 且最优值相等.